

# 1 นอร์มเวกเตอร์และนอร์มเมทริกซ์ (Vector Norms and Matrix Norms)

นอร์มเป็นวิธีการวัดขนาด โดยจะมีการกำหนดวิธีการวัดตามลักษณะของสิ่งที่วัด ทั้งเวกเตอร์และเมทริกซ์จะมีนอร์มที่ใช้ในการวัดขนาดที่มีการนิยามที่ต่างกัน หลายรูปแบบ ก่อนที่จะไปทำความรู้จักนิยามของนอร์มเวกเตอร์ ขอทบทวนนิยามของปริภูมิเวกเตอร์ (vector space) ดังนี้

**นิยาม 1.1.** [9] ให้  $V$  เป็นเซตใด ๆ โดยที่  $V \neq \emptyset$  และมีการดำเนินการ 2 อย่าง คือ การบวก  $\oplus$  และการคูณด้วยสเกลาร์  $\odot$  บนเซตของจำนวนจริง  $\mathbb{R}$  เราจะเรียกเซต  $V$  และ การดำเนินการทั้งสองว่า ปริภูมิเวกเตอร์ ก็ต่อเมื่อ สำหรับทุก  $u, v, w \in V$  และสเกลาร์  $c \in \mathbb{R}$  ระบบดังกล่าวมีสมบัติครบ 10 ข้อ ต่อไปนี้

1.  $u \oplus v \in V$
2.  $u \oplus v = v \oplus u$
3.  $(u \oplus v) \oplus w = v \oplus (u \oplus w)$
4. มี  $0 \in V$  ที่ทำให้  $u \oplus 0 = u$
5. สำหรับทุก ๆ  $u \in V$  จะมี  $-u \in V$  ที่ทำให้  $u \oplus (-u) = 0$
6.  $c \odot u \in V$
7.  $c \odot (u \oplus v) = (c \odot u) \oplus (c \odot v)$
8.  $(c + d) \odot u = (c \odot u) \oplus (d \odot v)$
9.  $(cd) \odot u = c \odot (d \odot u)$
10. มี  $1 \in \mathbb{R}$  ที่ทำให้  $1 \odot u = u$

**หมายเหตุ** สมบัติข้อ 1 และ 6 เรียกว่าสมบัติปิด ซึ่งบางครั้งในการเขียนสมบัติของปริภูมิเวกเตอร์จะละไว้

**ตัวอย่าง 1.2.**  $V = \mathbb{R}^2$  และการดำเนินการ

$$(x_1, x_2) + (y_1, y_2) = (x_1 + y_1, x_2 + y_2)$$

$$k(x_1, x_2) = (kx_1, kx_2) \text{ เมื่อ } k \in \mathbb{R} \text{ เป็นสเกลาร์}$$

$V$  และการดำเนินการทั้งสองเป็นปริภูมิเวกเตอร์

ปริภูมิเวกเตอร์ของจำนวนจริง  $\mathbb{R}^n$  มักจะเรียกว่า ปริภูมิยูคลิด (Euclidean  $n$ -space) และปริภูมิเวกเตอร์ของจำนวนเชิงซ้อน คือ  $\mathbb{C}^n$  [3]

## 1.1 Vector Norms

**นิยาม 1.3.** ให้  $E$  เป็น vector space บนจำนวนจริง  $\mathbb{R}$  **นอร์มบน  $E$**  คือ ฟังก์ชัน  $\| \cdot \| : E \rightarrow \mathbb{R}_+$  ซึ่งจะให้ค่าที่เป็นจำนวนจริงที่ไม่เป็นลบ สำหรับทุกเวกเตอร์  $x, y \in E$  และ  $\lambda \in \mathbb{R}$  นอร์มเวกเตอร์สอดคล้องกับสมบัติต่อไปนี้

1.  $\|x\| \geq 0$
2.  $\|x\| = 0$  ก็ต่อเมื่อ  $x = 0$
3.  $\|\lambda x\| = |\lambda| \|x\|$
4.  $\|x + y\| \leq \|x\| + \|y\|$

vector space  $E$  และนอร์ม  $\| \cdot \|$  รวมกันจะเรียกเป็น normed vector space

**ตัวอย่าง 1.4.** กำหนด  $E$  ต่างกันจะได้นอร์ม ดังนี้

1. ให้  $E = \mathbb{R}$  จะได้  $\|x\| = |x|$  เป็นค่าสัมบูรณ์ของ  $x$
2. ให้  $E = \mathbb{R}^n$  ดังนั้น  $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$  จะมีนอร์มมาตรฐานที่ใช้กันอยู่ 3 แบบ ได้แก่

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$$

$$\|x\|_2 = (|x_1|^2 + |x_2|^2 + \dots + |x_n|^2)^{\frac{1}{2}}$$

$$\|x\|_\infty = \max \{|x_i| \mid 1 \leq i \leq n\}$$

โดย  $\| \cdot \|_2$  จะเรียกว่า Euclidean norm หรือ นอร์ม  $l_2$  และ  $\| \cdot \|_\infty$  เรียก นอร์ม  $l_\infty$

**ตัวอย่าง 1.5.** ระบบสมการเชิงเส้น

$$3.3330x_1 + 15920x_2 - 10.333x_3 = 15913$$

$$2.2220x_1 + 16.710x_2 + 9.6120x_3 = 29.544$$

$$1.5611x_1 + 5.1791x_2 + 1.6852x_3 = 8.4254$$

มีผลเฉลยแน่นอนตรง (exact solution) เป็น  $\mathbf{x} = (x_1, x_2, x_3)^t = (1, 1, 1)^t$  โดยการใช้วิธีการเชิงตัวเลข  
ได้ผลเฉลยโดยประมาณ (approximate solution) เป็น

$$\tilde{\mathbf{x}} = (1.2001, 0.99991, 0.92538)^t$$

จึงใช้นอร์ม  $l_2$  และ  $l_\infty$  ในการหาผลต่างของผลเฉลยแน่นอนตรงและผลเฉลยโดยประมาณ

**วิธีทำ** ผลต่างของผลเฉลยโดยประมาณและผลเฉลยแน่นอนตรง มีค่าเป็น  $\tilde{\mathbf{x}} - \mathbf{x} = (0.2001, -0.00009, -0.07462)^t$

$$\begin{aligned} \|\tilde{\mathbf{x}} - \mathbf{x}\|_2 &= (|0.2001|^2 + |-0.00009|^2 + |-0.07462|^2)^{\frac{1}{2}} \\ &= 0.21356 \end{aligned}$$

$$\begin{aligned} \|\tilde{\mathbf{x}} - \mathbf{x}\|_\infty &= \max \{|0.2001|, |-0.00009|, |-0.07462|\} \\ &= 0.2001 \end{aligned}$$

## 1.2 Matrix Norms

ทบทวนนิยามต่าง ๆ เกี่ยวกับเมทริกซ์

กำหนดเมทริกซ์  $A = (a_{ij}) \in M_{m,n}(\mathbb{C})$

- **สังยุค** (conjugate) ของเมทริกซ์  $A$  คือ  $\bar{A}$  และ  $\bar{A} = (\bar{a}_{ij})$
- **เมทริกซ์สลับสับเปลี่ยน** (transpose) ของเมทริกซ์  $A$  คือ  $A^t$  และ  $A^t = (\bar{a}_{ji})$
- **เมทริกซ์สังยุค สลับสับเปลี่ยน** (conjugate transpose) หรือ Hermitian transpose ของเมทริกซ์  $A$  ที่มีขนาด  $m \times n$  แทนด้วย  $A^*$  และ  $A^* = (\bar{A}^t) = (\bar{A})^t$   
ถ้า  $A$  เป็นเมทริกซ์ของจำนวนจริงจะได้  $A^* = A^t$
- ถ้า  $A$  เป็นเมทริกซ์ของจำนวนจริง  $A \in M_n(\mathbb{R})$  เมทริกซ์  $A$  จะเป็นเมทริกซ์**สมมาตร** (symmetric) เมื่อ  $A^t = A$
- เมทริกซ์  $A \in M_n(\mathbb{C})$  เป็นเมทริกซ์**ปรกติ** (normal) เมื่อ  $AA^* = A^*A$   
เมทริกซ์  $A \in M_n(\mathbb{R})$  เป็นเมทริกซ์ปรกติ เมื่อ  $AA^t = A^tA$
- เมทริกซ์  $Q \in M_n(\mathbb{R})$  เป็นเมทริกซ์**ตั้งฉาก** (orthogonal) ถ้า  $QQ^t = Q^tQ = I$
- เมทริกซ์  $U \in M_n(\mathbb{C})$  เป็นเมทริกซ์**ยูนิตารี** (unitary) เมื่อ  $U^*U = UU^* = I$
- กำหนดเมทริกซ์  $A = (a_{ij}) \in M_n(\mathbb{C})$  **เทรซ** (trace) ของเมทริกซ์  $A$  เขียนแทนด้วย  $tr(A)$  มีค่าเท่ากับผลบวกของสมาชิกในแนวทแยง นั่นคือ  $tr(A) = a_{11} + a_{22} + \cdots + a_{nn}$

**นิยาม 1.6.** [5] **เมทริกซ์นอร์ม** (matrix norm)  $\| \cdot \|$  บนสเปซของเมทริกซ์จัตุรัสขนาด  $n \times n$  ซึ่งแทนด้วยสัญลักษณ์  $M_n(K)$  โดยที่  $K = \mathbb{R}$  หรือ  $K = \mathbb{C}$  เป็นนอร์มบนเวกเตอร์สเปซ  $M_n(K)$  ที่มีสมบัติเพิ่มขึ้น ซึ่งเรียกว่า submultiplicativity

$$\|AB\| \leq \|A\| \|B\|$$

สำหรับทุก ๆ  $A, B \in M_n(K)$  นอร์มบนเมทริกซ์ที่สอดคล้องเงื่อนไขข้างต้นมักจะเรียกว่า submultiplicative matrix norm

**นิยาม 1.7.** นอร์มโฟรบีเนียส (Frobenius norm) แทนด้วยสัญลักษณ์  $\| \cdot \|_F$  กำหนดโดย

$$\|A\|_F = \left( \sum_{i,j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} = \sqrt{tr(AA^*)} = \sqrt{tr(A^*A)} \quad (1)$$

เมื่อ  $A$  เป็นเมทริกซ์จัตุรัสขนาด  $n \times n$  และ  $A \in M_n(\mathbb{C})$

**นิยาม 1.8.** สำหรับเมทริกซ์จัตุรัสใด  $A \in M_n(\mathbb{C})$  จำนวนเชิงซ้อน  $\lambda \in \mathbb{C}$  เป็นค่าไอเก้น (eigenvalue) ของเมทริกซ์  $A$  ถ้ามีเวกเตอร์  $u \neq 0$  และ  $u \in \mathbb{C}^n$  ซึ่ง

$$Au = \lambda u$$

ถ้า  $\lambda$  เป็นค่าไอเก้นของเมทริกซ์  $A$  แล้วเวกเตอร์ที่ไม่เป็นศูนย์  $u \in \mathbb{C}^n$  ซึ่งสอดคล้องกับ  $Au = \lambda u$  จะเรียกว่า เวกเตอร์ไอเก้น (eigenvector) ของเมทริกซ์  $A$  ที่สัมพันธ์กับค่าไอเก้น  $\lambda$  เมื่อนำเวกเตอร์ไอเก้นทั้งหมด รวมกับเวกเตอร์ศูนย์ จะเป็นสเปซย่อย (subspace) ของ  $\mathbb{C}^n$  แทนด้วย  $E_\lambda(A)$  และเรียกว่า eigenspace associated with  $\lambda$

**นิยาม 1.9.** ให้เมทริกซ์จัตุรัสขนาด  $n \times n$  ใด ๆ  $A \in M_n(\mathbb{C})$  พหุนาม

$$\det(\lambda I - A) = \lambda^n - \text{tr}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A) \quad (2)$$

เป็น characteristic polynomial ของเมทริกซ์  $A$  ค่ารากคำตอบ  $n$  ราก (ไม่จำเป็นต้องต่างกัน อาจซ้ำกันได้)  $\lambda_1, \lambda_2, \dots, \lambda_n$  ของสมการ (2) เป็นค่าไอเก้นทั้งหมดของเมทริกซ์  $A$  และ spectrum หรือ spectral radius ( $\rho$ ) ของเมทริกซ์  $A$  กำหนดดังนี้

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad (3)$$

**บทแทรก 1.10.** สำหรับนอร์มเมทริกซ์ใด ๆ  $\| \cdot \|$  บน  $M_n(\mathbb{R})$  และเมทริกซ์จัตุรัส  $A \in M_n(\mathbb{R})$  มีขนาด  $n \times n$  จะได้

$$\rho(A) \leq \|A\| \quad (4)$$

ตัวอย่าง 1.11. จงหา spectral radius ของเมทริกซ์

$$A = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & -1 \\ -1 & 1 & 1 \end{bmatrix}$$

วิธีทำ หาเมทริกซ์  $A - \lambda I$

$$A - \lambda I = \begin{bmatrix} 1 - \lambda & 0 & 2 \\ 0 & 1 - \lambda & -1 \\ -1 & 1 & 1 - \lambda \end{bmatrix}$$

จาก

$$\det(A - \lambda I) = 0 \quad (5)$$

จะได้

$$(1 - \lambda)^3 + 2(1 - \lambda) + (1 - \lambda) = 0$$

จัดรูป และแก้สมการจะได้  $\lambda_1 = 1, \lambda_{2,3} = 1 \pm \sqrt{3}i$

จากนิยามของ spectral radius จะได้

$$\rho(A) = \max\{|1|, |1 + \sqrt{3}i|, |1 - \sqrt{3}i|\} \quad (6)$$

$$= \max\{1, 2, 2\} \quad (7)$$

**ทฤษฎีบท 1.12.** กำหนดให้  $A$  เป็นเมทริกซ์จัตุรัสขนาด  $n \times n$  นอร์ม  $l_2$  ของเมทริกซ์  $A$  แทนด้วย  $\|A\|_2$

$$\|A\|_2 = \sqrt{\rho(A^t A)} \quad (8)$$

**ตัวอย่าง 1.13.** จงหา  $\|A\|_2$  เมื่อกำหนดเมทริกซ์  $A$  ดังนี้

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ -1 & 1 & 2 \end{bmatrix}$$

คำตอบ  $\|A\|_2 = \sqrt{7 + \sqrt{7}} \approx 3.11$

**นิยาม 1.14.** ถ้า  $|||$  เป็นนอร์มบน  $\mathbb{C}^n$  เรากำหนดฟังก์ชัน  $|||$  บน  $M_n(\mathbb{C})$  โดย

$$||A|| = \sup_{\substack{x \in \mathbb{C}^n \\ x \neq 0}} \frac{||Ax||}{||x||} = \sup_{\substack{x \in \mathbb{C}^n \\ ||x||=1}} ||Ax|| \quad (9)$$

ฟังก์ชันจาก  $A \rightarrow ||A||$  เรียกว่า subordinate matrix norm หรือ operator norm ที่เหนี่ยวนำโดยนอร์ม  $|||$

**บทแทรก 1.15.** สำหรับเมทริกซ์จัตุรัสใด ๆ  $A \in M_n(\mathbb{C})$  จะได้

$$||A||_1 = \sup_{\substack{x \in \mathbb{C}^n \\ ||x||_1=1}} ||Ax||_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$||A||_\infty = \sup_{\substack{x \in \mathbb{C}^n \\ ||x||_\infty=1}} ||Ax||_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad (10)$$

$$||A||_2 = \sup_{\substack{x \in \mathbb{C}^n \\ ||x||_2=1}} ||Ax||_2 = \sqrt{\rho(A^*A)} \quad (11)$$



**ตัวอย่าง 1.16.** กำหนดเมทริกซ์  $A = \begin{bmatrix} 2 & -1 & 3 \\ 1 & 1 & -1 \\ -4 & 2 & 1 \end{bmatrix}$

1-norm การหาค่าที่มากที่สุดของผลบวกในแต่ละหลัก (column)

$$\begin{aligned} \|A\|_1 &= \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \\ &= \max\{|2| + |1| + |-4|, |-1| + |1| + |2|, |3| + |-1| + |1|\} \\ &= \max\{7, 4, 5\} = 7 \end{aligned}$$

$\infty$ -norm การหาค่าที่มากที่สุดของผลบวกในแต่ละแถว (row)

$$\begin{aligned} \|A\|_\infty &= \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \\ &= \max\{|2| + |-1| + |3|, |1| + |1| + |-1|, |-4| + |2| + |1|\} \\ &= \max\{6, 3, 7\} = 7 \end{aligned}$$

Frobenius norm การหารากที่สองของผลบวกของสมาชิกทุกตัวยกกำลังสอง

$$\begin{aligned} \|A\|_F &= \left( \sum_{i,j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} \\ &= (|2|^2 + |-1|^2 + |3|^2 + |1|^2 + |1|^2 + |-1|^2 + |-4|^2 + |2|^2 + |1|^2)^{\frac{1}{2}} \\ &= \sqrt{38} \approx 6.16 \end{aligned}$$

### 1.3 ความคลาดเคลื่อนของการประมาณค่าและ condition number

ในระบบสมการเชิงเส้น  $Ax = b$  ในบางครั้งการปรับเปลี่ยนค่าเล็กน้อย อาจส่งผลมากต่อคำตอบของระบบสมการ

ตัวอย่าง 1.17. [2]

$$\begin{bmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 32 \\ 23 \\ 33 \\ 31 \end{bmatrix} \quad (12)$$

ระบบสมการนี้มีคำตอบเป็น  $x = (1, 1, 1, 1)$

เราเปลี่ยนค่าเล็กน้อยของเมทริกซ์ขวาสุด จะได้ระบบสมการ

$$\begin{bmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{bmatrix} \begin{bmatrix} x_1 + \Delta x_1 \\ x_2 + \Delta x_2 \\ x_3 + \Delta x_3 \\ x_4 + \Delta x_4 \end{bmatrix} = \begin{bmatrix} 32.1 \\ 22.9 \\ 33.1 \\ 30.9 \end{bmatrix} \quad (13)$$

ระบบสมการนี้มีคำตอบเป็น  $x = (9.2, -12.6, 4.5, -1.1)$

เราเปลี่ยนค่าเล็กน้อยของเมทริกซ์ จะได้ระบบสมการ

$$\begin{bmatrix} 10 & 7 & 8.1 & 7.2 \\ 7.08 & 5.04 & 6 & 5 \\ 8 & 5.98 & 9.98 & 9 \\ 6.99 & 4.99 & 9 & 9.98 \end{bmatrix} \begin{bmatrix} x_1 + \Delta x_1 \\ x_2 + \Delta x_2 \\ x_3 + \Delta x_3 \\ x_4 + \Delta x_4 \end{bmatrix} = \begin{bmatrix} 32 \\ 23 \\ 33 \\ 31 \end{bmatrix} \quad (14)$$

ระบบสมการนี้มีคำตอบเป็น  $x = (-81, 137, -34, 22)$

จะเห็นได้ว่า การเปลี่ยนแปลงค่าเพียงเล็กน้อยในระบบสมการ ส่งผลต่อคำตอบมหาศาล ปัญหาลักษณะแบบนี้เกิดจากเมทริกซ์ของสมการไม่ดี

**ทฤษฎีบท 1.18.** ให้  $\tilde{x}$  แทน คำตอบเชิงประมาณค่าของระบบสมการ  $Ax = b$  และ  $r$  เป็นเวกเตอร์เศษเหลือ (residual vector) ของ  $\tilde{x}$  แล้ว

$$\|x - \tilde{x}\| \leq \|A^{-1}\| \|r\|$$

และถ้า  $x \neq 0$  และ  $b \neq 0$

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \|A\| \|A^{-1}\| \frac{\|r\|}{\|b\|}$$

อสมการในทฤษฎีบท 1.18 ทำให้เห็นว่า  $\|A^{-1}\|$  และ  $\|A\| \|A^{-1}\|$  มีความเชื่อมโยงกันระหว่างเวกเตอร์เศษเหลือและความถูกต้องของการประมาณค่า

**นิยาม 1.19.** condition number ของเมทริกซ์ไม่เอกฐาน (nonsingular matrix) คือ

$$K(A) = \|A\| \|A^{-1}\| \quad (15)$$

เมทริกซ์  $A$  จะดี (well conditioned) ถ้า  $K(A)$  มีค่าเข้าใกล้ 1 และไม่ดี (ill conditioned) เมื่อค่าของ  $K(A)$  มีค่าไกลจาก 1 อย่างเห็นได้ชัด

**ตัวอย่าง 1.20.** จงหา condition number ของเมทริกซ์

$$A = \begin{bmatrix} 1 & 2 \\ 1.0001 & 2 \end{bmatrix}$$

**วิธีทำ** condition number สามารถหาได้จากสมการ (15)

$$\begin{aligned} A^{-1} &= \frac{1}{(1)(2) - (1.0001)(2)} \begin{bmatrix} 2 & -2 \\ -1.0001 & 1 \end{bmatrix} \\ &= \begin{bmatrix} -20000 & 20000 \\ 10001 & -10000 \end{bmatrix} \end{aligned}$$

เลือกใช้ 1-norm จะได้

$$\|A\|_1 = \max\{2.0001, 4\} = 4$$

$$\|A^{-1}\|_1 = \max\{30001, 30000\} = 30001$$

$$K(A) = 120004$$

ค่าของ  $K(A)$  มีค่ามากอย่างเห็นได้ชัด ดังนั้น เมทริกซ์  $A$  เป็น ill conditioned matrix

## แบบฝึกหัด

### 1. ระบบสมการเชิงเส้น

$$\begin{aligned}x - 2y + 3z &= 7 \\2x + y + z &= 4 \\-3x + 2y - 2z &= -10\end{aligned}$$

มีผลเฉลยแน่นอนตรง (exact solution) เป็น  $\mathbf{x} = (x, y, z)^t = (2, -1, 1)^t$

ใช้วิธีการเชิงตัวเลขได้ผลเฉลยโดยประมาณเป็น  $\tilde{\mathbf{x}} = (2.0175, -0.9987, 1.0001)^t$

จงใช้  $l_\infty$  ในการหาผลต่างของผลเฉลยแน่นอนตรงและผลเฉลยโดยประมาณ

### 2. กำหนดเมทริกซ์

$$A = \begin{bmatrix} 1 & -1 & 0 \\ 2 & 0 & -1 \\ 1 & 1 & -1 \end{bmatrix}$$

จงหาค่าของ Frobenious norm

### 3. กำหนดเมทริกซ์

$$A = \frac{1}{\sqrt{3}} \begin{bmatrix} 3 & -1 \\ 0 & \sqrt{8} \end{bmatrix}$$

3.1 จงหาค่าของ  $\|A\|_2$

3.2 จงหาค่าของ  $\|A^{-1}\|_2$

3.3 จงหาค่าไอเก้นของเมทริกซ์  $A$

### 4. จงหา condition number ของเมทริกซ์ต่อไปนี้โดยใช้ 1-norm ( $l_1$ )

$$A = \begin{bmatrix} 2 & 1 \\ 2.01 & 1 \end{bmatrix}$$

## 2 การแยกค่าเอกฐาน (Singular Value Decomposition)

### 2.1 Unitary และ Orthogonal Matrices

นิยามของ Unitary และ Orthogonal Matrices กำหนดดังในกรอบสี่เหลี่ยม

เมทริกซ์  $U \in M_n(\mathbb{C})$  เป็นเมทริกซ์ยูนิเทรี (unitary) เมื่อ  $U^*U = UU^* = I$  หรือกล่าวได้ว่า  
หลัก (หรือ แถว) ของเมทริกซ์  $U$  ประกอบด้วย orthonormal basis สำหรับ  $\mathbb{C}^n$   
เมทริกซ์  $Q \in M_n(\mathbb{R})$  เป็นเมทริกซ์ตั้งฉาก (orthogonal) ถ้า  $QQ^t = Q^tQ = I$  หรือกล่าวได้ว่า  
หลัก (หรือ แถว) ของเมทริกซ์  $Q$  ประกอบด้วย orthonormal basis สำหรับ  $\mathbb{R}^n$

เมื่อ orthonormal basis ของ inner product space  $V$  ที่มีสมาชิกเป็นเวกเตอร์ที่เป็น orthonormal  
หรือ กล่าวได้ว่า เป็นเวกเตอร์หน่วยและตั้งฉาก (orthogonal) กัน

Unitary และ Orthogonal Matrices มีสมบัติที่ดีบางอย่าง สิ่งแรก คือ ถ้าเมทริกซ์มี  
สมบัติเป็น Unitary หรือ Orthogonal จะหาเมทริกซ์ผกผัน (inverse matrix) ง่าย นั่นคือ ถ้า  $U$   
เป็น unitary จะได้  $U^{-1} = U^*$  โดยสามารถเห็นได้ชัดเจน กำหนดให้  $U_{n \times n} = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_n \end{bmatrix}$   
โดยที่  $\mathbf{u}_i$  เมื่อ  $i = 1, 2, \dots, n$  เป็น orthonormal vectors ก็ต่อเมื่อ

$$[U^*U]_{ij} = \mathbf{u}_i^* \mathbf{u}_j = \begin{cases} 1 & \text{เมื่อ } i = j \\ 0 & \text{เมื่อ } i \neq j \end{cases} \iff U^*U = I \iff U^{-1} = U^*$$

**ข้อสังเกต** เนื่องจาก  $U^*U = I \iff UU^* = I$  หลักของเมทริกซ์  $U$  เป็น orthonormal ก็ต่อเมื่อ  
แถวของ  $U$  เป็น orthonormal ดังนั้นในนิยามของยูนิเทรี และ orthonormal matrices สามารถ  
เขียนได้ทั้ง หลักหรือแถวเป็น orthonormal

ตัวอย่าง 2.1. พิจารณาเมทริกซ์ต่อไปนี้ ว่าเป็น ยูนิเทรี หรือ orthogonal เมทริกซ์ หรือไม่

1. เมทริกซ์เอกลักษณ์  $I$

$$2. Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{6}} \end{bmatrix}$$

$$3. U = \frac{1}{2} \begin{bmatrix} 1+i & -1+i \\ 1+i & 1-i \end{bmatrix}$$

วิธีทำ

1. เมทริกซ์เอกลักษณ์  $I$  ถ้ามองเป็นเมทริกซ์ขนาด  $n \times n$  จะได้

$$I = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} = \begin{bmatrix} \mathbf{i}_1 & \mathbf{i}_2 & \mathbf{i}_3 & \cdots & \mathbf{i}_n \end{bmatrix}$$

จะเห็นได้ว่า  $\mathbf{i}_k \cdot \mathbf{i}_l = 0$  โดยที่  $k \neq l$  และ  $|\mathbf{i}_k| = 1$  เมื่อ  $k = 1, 2, \dots, n$   
 ดังนั้น  $I$  เป็น orthogonal matrix

2.

$$Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{6}} \end{bmatrix} = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 & \mathbf{q}_3 \end{bmatrix} \quad (16)$$

เวกเตอร์

$$\mathbf{q}_1 \cdot \mathbf{q}_2 = \left(\frac{1}{\sqrt{2}}\right) \left(\frac{1}{\sqrt{3}}\right) + \left(-\frac{1}{\sqrt{2}}\right) \left(\frac{1}{\sqrt{3}}\right) + (0) \left(\frac{1}{\sqrt{3}}\right) = 0$$

ดังนั้น  $\mathbf{q}_1$  ตั้งฉาก  $\mathbf{q}_2$

ในทำนองเดียวกัน จะได้  $\mathbf{q}_1$  ตั้งฉาก  $\mathbf{q}_3$  และ  $\mathbf{q}_2$  ตั้งฉาก  $\mathbf{q}_3$

และ

$$|\mathbf{q}_1| = \sqrt{\left(\frac{1}{\sqrt{2}}\right)^2 + \left(-\frac{1}{\sqrt{2}}\right)^2 + (0)^2} = 1$$

ในทำนองเดียวกัน  $|\mathbf{q}_2| = |\mathbf{q}_3| = 1$

ดังนั้น จะได้ว่าเมทริกซ์  $Q$  เป็น orthogonal matrix

หรือ อาจจะได้โดยการนำเมทริกซ์  $Q$  และ  $Q^t$  มาคูณกัน ก็จะได้

$$QQ^t = Q^tQ = I$$

3. ในการแสดงว่าเมทริกซ์  $U$  เป็น unitary matrix สามารถทำได้โดยการแสดงว่า

$$UU^* = U^*U = I$$

$$U = \frac{1}{2} \begin{bmatrix} 1+i & -1+i \\ 1+i & 1-i \end{bmatrix}$$

$$U^* = (\overline{U})^t \text{ ดังนั้น } U^* = \frac{1}{2} \begin{bmatrix} 1-i & 1-i \\ -1-i & 1+i \end{bmatrix}$$

จะได้

$$\begin{aligned} UU^* &= \frac{1}{2} \begin{bmatrix} 1+i & -1+i \\ 1+i & 1-i \end{bmatrix} \frac{1}{2} \begin{bmatrix} 1-i & 1-i \\ -1-i & 1+i \end{bmatrix} \\ &= \frac{1}{4} \begin{bmatrix} (1+i)(1-i) + (-1+i)(-1-i) & (1+i)(1-i) + (-1+i)(1+i) \\ (1+i)(1-i) + (1-i)(-1-i) & (1+i)(1-i) + (1-i)(1+i) \end{bmatrix} \\ &= \frac{1}{4} \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \end{aligned}$$

ในทำนองเดียวกันจะได้  $U^*U = I$  จึงสามารถสรุปได้ว่า เมทริกซ์  $U$  เป็น unitary matrix

## 2.2 ค่าไอเก้นและเวกเตอร์ไอเก้น

จากนิยาม 1.8 สำหรับเมทริกซ์จัตุรัสใด  $A \in M_n(\mathbb{C})$  จำนวนเชิงซ้อน  $\lambda \in \mathbb{C}$  เป็นค่าไอเก้น (eigenvalue) ของเมทริกซ์  $A$  ถ้ามีเวกเตอร์  $u \neq 0$  และ  $u \in \mathbb{C}^n$  ซึ่ง

$$Au = \lambda u$$

ถ้า  $\lambda$  เป็นค่าไอเก้นของเมทริกซ์  $A$  แล้วเวกเตอร์ที่ไม่เป็นศูนย์  $u \in \mathbb{C}^n$  ซึ่งสอดคล้องกับ  $Au = \lambda u$  จะเรียกว่า เวกเตอร์ไอเก้น (eigenvector) ของเมทริกซ์  $A$  ที่สัมพันธ์กับค่าไอเก้น  $\lambda$

**ตัวอย่าง 2.2.** กำหนดเมทริกซ์  $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

1. จงหาค่าไอเก้น และเวกเตอร์ไอเก้นที่สัมพันธ์กัน
2. จงหา orthogonal matrix ของ  $A$

### วิธีทำ

1. จาก  $|A - \lambda I|$  จะได้  $\lambda = 1, 3$  โดยกำหนดให้  $\lambda_1 = 1$  และ  $\lambda_2 = 3$   
สำหรับ  $\lambda_1 = 1$  หา eigenvector  $\mathbf{v}_1$  จาก  $A\mathbf{v}_1 = \lambda_1\mathbf{v}_1$  หรือ  $(A - \lambda_1 I)\mathbf{v}_1 = \mathbf{0}$

$$\begin{aligned} \begin{bmatrix} 2 - \lambda_1 & 1 \\ 1 & 2 - \lambda_1 \end{bmatrix} \begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} v_{11} + v_{12} \\ v_{11} + v_{12} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \end{aligned}$$

ดังนั้นจะได้สมการ 2 สมการที่ไม่อิสระต่อกัน (linearly dependence) จาก  $v_{11} + v_{12} = 0$  ให้  $v_{11} = 1$  จะได้  $v_{12} = -1$  ดังนั้นจะได้

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$



สำหรับ  $\lambda_2 = 3$  หา eigenvector  $\mathbf{v}_2$  จาก  $A\mathbf{v}_2 = \lambda_2\mathbf{v}_2$  หรือ  $(A - \lambda_2 I)\mathbf{v}_2 = \mathbf{0}$

$$\begin{aligned} \begin{bmatrix} 2 - \lambda_2 & 1 \\ 1 & 2 - \lambda_2 \end{bmatrix} \begin{bmatrix} v_{21} \\ v_{22} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} v_{21} \\ v_{22} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \begin{bmatrix} -v_{21} + v_{22} \\ v_{21} - v_{22} \end{bmatrix} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \end{aligned}$$

ดังนั้นจะได้สมการ 2 สมการที่ไม่อิสระต่อกัน (linearly dependence) จาก  $-v_{21} + v_{22} = 0$  ให้  $v_{21} = 1$  จะได้  $v_{22} = 1$  ดังนั้นจะได้

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

2. ให้  $Q$  แทน orthogonal matrix ของเมทริกซ์  $A$   
จาก eigenvectors โดยที่  $|\mathbf{v}_1| = |\mathbf{v}_2| = \sqrt{2}$  ดังนั้น จะได้

$$Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

โดยสามารถตรวจสอบความถูกต้องได้โดย

- (1)  $\mathbf{v}_1$  และ  $\mathbf{v}_2$  เป็นเวกเตอร์ตั้งฉากกัน โดยสามารถตรวจสอบได้จาก  $\mathbf{v}_1 \cdot \mathbf{v}_2 = 0$
- (2)  $QQ^t = Q^tQ = I$

**ทฤษฎีบท 2.3.** (Singular Value Decomposition) [6] สำหรับเมทริกซ์  $A$  ที่มีขนาด  $m \times n$  จะมี  $U$  และ  $V$  เป็นเมทริกซ์ตั้งฉาก (orthogonal matrix) โดยที่เมทริกซ์  $U$  มีขนาด  $n \times n$  เมทริกซ์  $V$  มีขนาด  $m \times m$  และ  $D$  เป็นเมทริกซ์แนวทแยง (diagonal matrix) ที่ทำให้  $A = VDU^T$  โดยที่  $D$  อยู่ในรูป

$$D = \begin{bmatrix} \sigma_1 & & \cdots & & \\ & \sigma_2 & & \cdots & \\ & \vdots & \vdots & \ddots & \vdots \\ & & & \cdots & \sigma_n \\ 0 & \vdots & \cdots & 0 & \\ \vdots & \vdots & \ddots & \vdots & \\ 0 & \vdots & \cdots & 0 & \end{bmatrix} \quad \text{หรือ} \quad D = \begin{bmatrix} \sigma_1 & \cdots & 0 & \cdots & 0 \\ & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & 0 & \vdots & 0 \\ & & \cdots & \sigma_m & 0 & \cdots & 0 \end{bmatrix}$$

โดยที่  $\sigma_1, \sigma_2, \dots, \sigma_r$  เป็น ค่าเอกพจน์ (singular values) ของ  $f$  นั่นคือ รากที่สองของค่าไอเก้นที่ไม่เป็นศูนย์ของ  $AA^t$  และ  $A^tA$  และ  $\sigma_{r+1} = \sigma_{r+2} = \dots = \sigma_p = 0$  เมื่อ  $p = \min\{m, n\}$  หลัก (column) ของเมทริกซ์  $U$  เป็นเวกเตอร์ไอเก้นของ  $A^tA$  และ หลัก (column) ของเมทริกซ์  $V$  เป็นเวกเตอร์ไอเก้นของ  $AA^t$

**พิสูจน์.** เนื่องจาก  $A^tA$  เป็น positive semidefinite matrix จะมีเมทริกซ์  $U$  ที่เป็น orthogonal matrix ที่ทำให้

$$A^tA = U\Sigma^2U^t \quad (17)$$

โดยที่เมทริกซ์  $D = \text{diag}[\sigma_1, \sigma_2, \dots, \sigma_r, 0, \dots, 0]$

โดยที่  $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$  เป็นค่าไอเก้นที่ไม่เป็นศูนย์ของเมทริกซ์  $A^tA$

$r$  เป็นเรงค์ (rank) ของเมทริกซ์  $A$  สังเกตได้ว่า  $r = \min\{m, n\}$

$AU$  เป็นเมทริกซ์ขนาด  $m \times n$  จะได้

$$U^tA^tAU = (AU)^tAU = \Sigma^2$$

ให้  $f_i \in \mathbb{R}^m$  เป็นหลักที่  $j$  ของเมทริกซ์  $AU$  สำหรับ  $j = 1, 2, \dots, n$  จะได้

$$\langle f_i, f_j \rangle = \sigma_i^2 \delta_{ij} \quad \text{เมื่อ} \quad 1 \leq i, j \leq r$$

และ

$$f_j = 0 \quad \text{เมื่อ} \quad r+1 \leq j \leq n$$

ถ้าเรากำหนดค่า  $[v_1, v_2, \dots, v_r]$  โดย

$$v_j = \sigma_j^{-1} f_j \quad \text{เมื่อ} \quad 1 \leq j \leq r$$

แล้ว เราจะได้

$$\langle v_i, v_j \rangle = \delta_{ij} \quad \text{เมื่อ} \quad 1 \leq i, j \leq r$$

เนื่องจาก  $f_i = \sigma_j v_j$  สำหรับ  $j = 1, 2, \dots, r$  จะได้

$$\langle v_i, f_j \rangle = \sigma_j \langle v_i, v_j \rangle = \sigma_j \delta_{ij} \quad \text{เมื่อ} \quad 1 \leq i \leq m, 1 \leq j \leq r$$

และเนื่องจาก  $f_j = 0$  สำหรับ  $j = r+1, r+2, \dots, n$  จะได้

$$\langle v_i, f_j \rangle = 0 \quad \text{เมื่อ} \quad 1 \leq i \leq m, r+1 \leq j \leq n$$

ถ้าแต่ละหลักของเมทริกซ์  $V$  ประกอบด้วย  $v_1, v_2, \dots, v_m$  แล้วเมทริกซ์  $V$  จะเป็น เมทริกซ์  
ขนาด  $m \times m$  และเป็นเมทริกซ์ตั้งฉาก

ถ้า  $m \geq n$  จะได้

$$D = \begin{bmatrix} \Sigma \\ 0_{m-n} \end{bmatrix} = \begin{bmatrix} \sigma_1 & \cdots & & \\ & \sigma_2 & \cdots & \\ \vdots & \vdots & \ddots & \vdots \\ & & \cdots & \sigma_n \\ 0 & \vdots & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \vdots & \cdots & 0 \end{bmatrix}$$

ถ้า  $n \geq m$  จะได้

$$D = \begin{bmatrix} \sigma_1 & \cdots & 0 & \cdots & 0 \\ & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & 0 & \vdots & 0 \\ & & \cdots & \sigma_m & 0 & \cdots & 0 \end{bmatrix}$$

ดังนั้น จึงสามารถพิสูจน์ได้ว่า

$$V^t A U = D$$

เมื่อจัดรูป จะได้  $A = V D U^t$  ตามที่ต้องการ

จาก สมการ

$$A = VDU^t \quad (18)$$

คูณสมการ (18) ด้วย  $A^t$  ทั้งทางซ้ายและทางขวา จะได้

$$A^t A = UD^t DU^t = U \text{diag}[\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, \underbrace{0, 0, \dots, 0}_{n-r}] U^t$$

และ

$$AA^t = VD^t DV^t = V \text{diag}[\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, \underbrace{0, 0, \dots, 0}_{m-r}] V^t$$

ซึ่งแสดงได้ว่าทั้ง  $A^t A$  และ  $AA^t$  มีค่าไอเก้นที่ไม่เป็นศูนย์เหมือนกัน สมาชิกในหลักของเมทริกซ์  $U$  คือ เวกเตอร์ไอเก้นของเมทริกซ์  $A^t A$  และ สมาชิกในหลักของเมทริกซ์  $V$  คือ เวกเตอร์ไอเก้นของเมทริกซ์  $AA^t$  □

**ตัวอย่าง 2.4.** กำหนดเมทริกซ์  $A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$

จงหา singular value decomposition

**วิธีทำ** หาเมทริกซ์  $U$   $V$  และ  $D$  ที่ทำให้ได้  $A = VDU^t$

$V$  ประกอบด้วยเวกเตอร์ไอเก้นของเมทริกซ์  $AA^t$

$U$  ประกอบด้วยเวกเตอร์ไอเก้นของเมทริกซ์  $A^tA$

$D$  ประกอบด้วยรากที่สองของค่าไอเก้นที่ไม่เป็นศูนย์ของ  $AA^t$  หรือ  $A^tA$

$$A^t = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

$$A^tA = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

หาค่าไอเก้น

$$|A^tA - \lambda I| = \begin{vmatrix} 1-\lambda & 1 \\ 1 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 - 1 = 1 - 2\lambda + \lambda^2 - 1 = \lambda^2 - 2\lambda = 0$$

แก้สมการ จะได้  $\lambda_1 = 2, \lambda_2 = 0$

จาก  $\lambda_1 = 2$  หาเวกเตอร์ไอเก้น  $\mathbf{u}_1$

$$(A^tA - \lambda_1 I)\mathbf{u}_1 = \mathbf{0}$$

$$\begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} u_{11} \\ u_{12} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

จะได้ระบบสมการ

$$-u_{11} + u_{12} = 0$$

$$u_{11} - u_{12} = 0$$

ให้  $u_{12} = 1$  จะได้  $u_{11} = 1$  ดังนั้น จะได้เวกเตอร์ไอเก้น

$$\mathbf{u}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

จาก  $\lambda_2 = 0$  หาเวกเตอร์ไอเก้น  $\mathbf{u}_2$

$$(A^t A - \lambda_2 I) \mathbf{u}_2 = \mathbf{0}$$

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} u_{21} \\ u_{22} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

จะได้ระบบสมการ

$$u_{21} + u_{22} = 0$$

$$u_{21} + u_{22} = 0$$

ให้  $u_{21} = 1$  จะได้  $u_{22} = -1$  ดังนั้น จะได้เวกเตอร์ไอเก้น

$$\mathbf{u}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$|\mathbf{u}_1| = |\mathbf{u}_2| = \sqrt{2}$$

ดังนั้น

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

หาเมทริกซ์  $V$  จาก

$$AA^t = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

หาค่าไอเก้น

$$|AA^t - \lambda I| = \begin{vmatrix} 2 - \lambda & 0 & 0 \\ 0 & -\lambda & 0 \\ 0 & 0 & -\lambda \end{vmatrix} = \lambda^2(2 - \lambda) = 0$$

แก้สมการ จะได้  $\lambda_1 = 2, \lambda_2 = 0, \lambda_3 = 0$

จาก  $\lambda_1 = 2$  หาเวกเตอร์ไอเก้น  $\mathbf{v}_1$

$$(AA^t - \lambda_1 I) \mathbf{v}_1 = \mathbf{0}$$

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -2 \end{bmatrix} \begin{bmatrix} v_{11} \\ v_{12} \\ v_{13} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

จะได้ระบบสมการ

$$-2v_{12} = 0$$

$$-2v_{13} = 0$$

ให้  $v_{12} = 0$  จะได้  $v_{13} = 0$  เลือกให้  $v_{11} = 1$  ดังนั้น จะได้เวกเตอร์ไอเก้น

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

จาก  $\lambda_2 = \lambda_3 = 0$  หาเวกเตอร์ไอเก้น  $\mathbf{v}_2$  และ  $\mathbf{v}_3$

$$(AA^t - \lambda_2 I)\mathbf{v}_2 = \mathbf{0}$$
$$\begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} v_{21} \\ v_{22} \\ v_{23} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

จะได้สมการ

$$2v_{21} = 0$$

จะได้  $v_{21} = 0$  ให้  $v_{22} = 1$  และ  $v_{23} = 0$  จะได้เวกเตอร์ไอเก้น

$$\mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

ให้  $v_{22} = 0$  และ  $v_{23} = 1$  จะได้เวกเตอร์ไอเก้น

$$\mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$|\mathbf{v}_1| = |\mathbf{v}_2| = |\mathbf{v}_3| = 1$$

ดังนั้น

$$V = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

และ

$$D = \begin{bmatrix} \sqrt{2} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

ในการคำนวณ singular value decomposition ค่อนข้างใช้การคำนวณเยอะสำหรับเมทริกซ์ที่มีขนาดใหญ่ ดังนั้นจึงมีการพัฒนาการเขียนโปรแกรมสำหรับการแยกเมทริกซ์ ดังตัวอย่างต่อไปนี้ ซึ่งใช้ภาษา python โดยอาจจะลองใช้คำสั่งบน google colab ได้ ซึ่งจะได้คำตอบออกมาเช่นเดียวกับตัวอย่าง 2.4 [4]

```
# Singular-value decomposition
from numpy import array
from scipy.linalg import svd
# define a matrix
A = array([[1, 1], [0, 0], [0, 0]])
print(A)
# SVD
U, s, VT = svd(A)
print(U)
print(s)
print(VT)
```

```
[[1 1]
 [0 0]
 [0 0]]
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]
[1.41421356 0.          ]
[[ 0.70710678  0.70710678]
 [-0.70710678  0.70710678]]
```



ตัวอย่าง 2.5. [7] การประยุกต์ใช้ SVD กับปัญหาที่มาจากข้อมูล ตัวอย่างนี้เป็น การเก็บข้อมูลของ ภาพยนตร์ 5 เรื่อง ซึ่งเป็นภาพยนตร์แนววิทยาศาสตร์ และแนวกโรแมนติก


เป้าหมาย คือ หาคคนที่ชอบดูภาพยนตร์ เรื่อง Matrix

## Case study: How to query?

- Q: Find users that like 'Matrix'
- A: Map query into a 'concept space' – how?

$$\begin{array}{c} \text{SciFi} \\ \updownarrow \\ \text{Romnce} \end{array} \begin{array}{c} \text{Matrix} \\ \text{Alien} \\ \text{Serenity} \\ \text{Casablanca} \\ \text{Amelie} \end{array} = \begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & 0.09 \end{bmatrix}$$

ในการที่จะคาดการณ์จากข้อมูลที่มีว่า แต่ละคน จะชอบภาพยนตร์ เรื่อง Matrix หรือไม่ จะเริ่มต้นจากการทำ concept space



ลองใช้กับข้อมูลของคนที่ดูภาพยนตร์ เรื่อง Matrix

$$q_{\text{concept}} = q V$$


E.g.:

$$q = \begin{bmatrix} \text{Matrix} \\ \text{Alien} \\ \text{Serenity} \\ \text{Casablanca} \\ \text{Amelie} \end{bmatrix} = \begin{bmatrix} 5 & 0 & 0 & 0 & 0 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.12 \\ 0.59 & -0.02 \\ 0.56 & 0.12 \\ 0.09 & -0.69 \\ 0.09 & -0.69 \end{bmatrix} = \begin{bmatrix} 2.8 & 0.6 \end{bmatrix}$$

movie-to-concept similarities (V)

SciFi-concept

เปรียบเทียบ input 2 แบบ โดยคนนึงเคยดู แต่อีกคนไม่เคยดู ภาพยนตร์ เรื่อง Matrix แต่ได้ผลลัพธ์ไปในทางเดียวกัน คือ ชอบดูภาพยนตร์แนว SciFi ทั้งคู่ จึงสามารถตอบได้ว่า คนนี้จะชอบดูภาพยนตร์เรื่อง Matrix



## แบบฝึกหัด

1. กำหนดเมทริกซ์

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & 2 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 \end{bmatrix}$$

จงตรวจสอบว่าเวกเตอร์  $V$   $D$  และ  $U^t$  ที่กำหนดให้ต่อไปนี้ เป็น Singular value decomposition หรือไม่

$$V = \begin{bmatrix} 0 & -1 & 0 & 0 \\ -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 \\ 0 & 0 & -1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 3 & 0 & 0 & 0 & 0 \\ 0 & \sqrt{5} & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$U^t = \begin{bmatrix} 0 & 0 & -1 & 0 & 0 \\ -\sqrt{0.2} & 0 & 0 & 0 & -\sqrt{0.8} \\ 0 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ -\sqrt{0.8} & 0 & 0 & 0 & \sqrt{0.2} \end{bmatrix}$$

2. กำหนดเมทริกซ์  $A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$

จงใช้ singular value decomposition ในการแยกเมทริกซ์  $A$  ให้อยู่ในรูป  $A = VDU^t$  พร้อมทั้งแสดงวิธีการตรวจคำตอบ

3. กำหนดเมทริกซ์  $A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$

จงใช้ singular value decomposition ในการแยกเมทริกซ์  $A$  ให้อยู่ในรูป  $A = VDU^t$  พร้อมทั้งแสดงวิธีการตรวจคำตอบ

## หนังสืออ้างอิง

- [1] Singular value decomposition. <https://en.wikipedia.org>.
- [2] <https://www.cis.upenn.edu/cis515/cis515-11-sl4.pdf>, January 2021.
- [3] vector space. <https://mathworld.wolfram.com>, January 2021.
- [4] J. Brownlee. How to calculate the svd from scratch with python. <https://machinelearningmastery.com/singular-value-decomposition-for-machine-learning/>.
- [5] M. P. Deisenroth, A. A. Faisal, and C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, England, 2019.
- [6] J. Gallier and J. Quaintance. *Linear Algebra for Computer Vision, Robotics, and Machine Learning*. University of Pennsylvania, USA, 2019.
- [7] Leskovec, Rajaraman, and Ullman. Lecture 50 — svd example and conclusion | stanford university.
- [8] C. D. Meyer. *Matrix Analysis and Applied Linear Algebra*. SIAM, USA, 2000.
- [9] W.T.MathKKU. 321211 Linear Algebra I. <https://home.kku.ac.th/wattou/teaching/321211/101.pdf>.